Université de Lille – M2 MIAGE

OAFD – Optimisation et Apprentissage par Fouille de Données

RAPPORT DE PROJET

Classification Partielle Multi-Objectif

avec Algorithmes Génétiques Multi-Objectifs (JMetalPy)

Réalisé par :

Ikram HAMZAOUI

Salas MERZOUK

Salim TITOUCHE

Année universitaire 2025–2026

Introduction

Ce rapport présente la Partie 2 de notre projet OAFD : la Classification Partielle Multi-Objectif par Algorithme Génétique avec JMetalPy. Il fait suite à la Partie 1 (classification partielle mono-objectif) dont nous réutilisons les résultats Scikit-Learn comme baselines de comparaison.

Dans la Partie 1, nous avons cherché des règles maximisant la F1-mesure (un seul objectif). Dans cette Partie 2, nous séparons ce critère composite en deux objectifs distincts optimisés simultanément :

- Objectif 1 : Confiance (Precision) – maximiser la précision des prédictions positives
- Objectif 2 : Sensibilité (Recall) – maximiser la couverture des vrais positifs

Cette approche multi-objectif permet d'explorer l'ensemble des compromis entre confiance et sensibilité, et de présenter au décideur (médecin, biologiste) un front Pareto de solutions plutôt qu'un unique compromis figé.

Nous implémentons et comparons deux algorithmes génétiques multi-objectifs :

- NSGA-II (Non-dominated Sorting Genetic Algorithm II)
- SPEA2 (Strength Pareto Evolutionary Algorithm 2)

L'évaluation est réalisée sur les jeux de données PIMA Diabetes et Yeast1 avec une validation croisée stratifiée 3-fold (même protocole que la Partie 1), et les résultats sont comparés aux algorithmes Scikit-Learn : Random Forest, SVM et C4.5.

Partie 1 – Rappel des Résultats Scikit-Learn

Les résultats Scikit-Learn ont été obtenus avec une validation croisée StratifiedKFold (3 folds, seed = 42). Ces valeurs servent de points de référence pour positionner les solutions des algorithmes génétiques multi-objectifs dans l'espace Confiance × Sensibilité.

1.1 Dataset PIMA Diabetes

Algorithme	F1-mesure (moy ± σ)	Confiance (moy ± σ)	Sensibilité (moy ± σ)
Random Forest	0.625 ± 0.022	0.692 ± 0.054	0.578 ± 0.063
SVM	0.563 ± 0.022	0.721 ± 0.021	0.463 ± 0.023
C4.5	0.555 ± 0.028	0.696 ± 0.065	0.474 ± 0.071

Random Forest obtient le meilleur F1 (0.625) et la meilleure sensibilité (0.578). SVM se distingue par sa confiance maximale (0.721) au détriment d'un recall faible (0.463). C4.5, seule boîte blanche native de sklearn, reste compétitif (F1=0.555) mais inférieur aux deux autres.

1.2 Dataset Yeast1

Algorithme	F1-mesure (moy ± σ)	Confiance (moy ± σ)	Sensibilité (moy ± σ)
Random Forest	0.537 ± 0.038	0.644 ± 0.039	0.464 ± 0.051
SVM	0.413 ± 0.060	0.707 ± 0.100	0.301 ± 0.071
C4.5	0.512 ± 0.053	0.577 ± 0.063	0.478 ± 0.106

Sur Yeast1 (déséquilibre 71% négatifs / 29% positifs), Random Forest domine sur les trois métriques. SVM souffre fortement du déséquilibre de classes avec un recall très faible (0.301), confirmant son biais vers la classe majoritaire. C4.5 offre un meilleur équilibre mais avec une variance plus élevée (σ=0.106 sur le recall).

Ces points Scikit-Learn seront représentés graphiquement sur les fronts Pareto (Confiance × Sensibilité) des algorithmes génétiques multi-objectifs, permettant une comparaison visuelle directe.

Partie 2 – Modélisation du Problème Multi-Objectif

2.1 Du mono-objectif au multi-objectif

Dans la Partie 1, l'algorithme génétique optimisait un objectif unique :

```
objectif = −F1 = −(2 × Precision × Recall) / (Precision + Recall)
```

La F1-mesure fusionne Precision et Recall en un scalaire, masquant les compromis entre les deux. Dans cette Partie 2, on les sépare en deux objectifs indépendants optimisés simultanément :

Objectif	Formule JMetalPy	Signification
obj[0]	*−Precision*	Minimiser −Precision = maximiser la confiance
obj[1]	*−Recall*	Minimiser −Recall = maximiser la sensibilité

JMetalPy minimise toujours. En passant les objectifs en négatif, on maximise effectivement Precision et Recall simultanément. Si la règle ne prédit aucun positif (y_pred tout à zéro), les deux objectifs sont fixés à 0.0 pour éviter toute division par zéro.

2.2 Représentation Michigan (inchangée)

La représentation des solutions reste identique à la Partie 1 : chaque individu encode une unique règle de la forme :

```
SI attr_i ∈ [lo_i, hi_i] ET attr_j ∈ [lo_j, hi_j] ET ... → classe positive
```

Le vecteur solution contient 2 × n_attributs flottants (16 variables pour n=8 attributs). La convention d'activation est inchangée :

- Si lo_i ≤ hi_i → attribut activé (condition appliquée)
- Si lo_i > hi_i → attribut désactivé (ignoré dans la règle)

2.3 Front de Pareto et Hypervolume

L'approche multi-objectif produit non plus une unique solution, mais un ensemble de solutions non-dominées formant le front de Pareto approché. Une solution A domine une solution B si :

- A est au moins aussi bonne que B sur tous les objectifs
- A est strictement meilleure que B sur au moins un objectif

La qualité globale du front Pareto est mesurée par l'Hypervolume (HV) : la surface de l'espace dominée par le front par rapport à un point de référence. Un HV plus élevé indique un meilleur front (couvrant plus de compromis de bonne qualité). Nous utilisons le point de référence [0.05, 0.05] dans l'espace de minimisation (−Precision, −Recall).

2.4 Protocole de comparaison avec Scikit-Learn

Les algorithmes MO produisant plusieurs solutions, nous appliquons le protocole suivant :

Étape	Description
Étape 1	Tracer les fronts Pareto obtenus. Sélectionner pour chaque AG le run avec le meilleur HV sur le training.
Étape 2	Superposer les points Scikit-Learn (Confiance, Sensibilité) sur le graphe des fronts Pareto.
Étape 3	Évaluer sur le jeu de test les solutions retenues à l'Étape 1. Sélectionner la solution présentée au client : celle avec le meilleur F1 sur le training.

Partie 3 – Implémentation dans JMetalPy

3.1 Classe PartialClassifMO

La classe PartialClassifMO hérite de Problem (JMetalPy) et étend PartialClassifMichigan en déclarant deux objectifs au lieu d'un. Les modifications par rapport à la Partie 1 sont minimales et ciblées :

Méthode	Partie 1 (Mono-obj)	Partie 2 (Multi-obj)
number_of_objectives()	*return 1*	***return 2***
obj_directions	*[MINIMIZE]*	***[MINIMIZE, MINIMIZE]***
evaluate() – objectifs	*obj[0] = −F1*	***obj[0]=−Precision, obj[1]=−Recall***
__init__, create_solution, _decode	Inchangés	Inchangés

La méthode evaluate() est la seule à changer substantiellement. Au lieu de calculer la F1-mesure et de retourner son opposé, elle calcule séparément la Precision et le Recall :

```
solution.objectives[0] = -precision_score(y, y_pred, zero_division=0)
solution.objectives[1] = -recall_score(y, y_pred, zero_division=0)
```

3.2 Algorithmes Multi-Objectifs utilisés

3.2.1 NSGA-II – Non-dominated Sorting Genetic Algorithm II

NSGA-II est l'algorithme multi-objectif de référence. À chaque génération :

- Tri non-dominé : les solutions sont classées par rangs (rang 1 = front Pareto, rang 2 = dominées uniquement par le rang 1, etc.)
- Distance de crowding : au sein d'un même rang, on préfère les solutions les plus éloignées de leurs voisins pour maintenir la diversité du front
- Sélection : priorité aux rangs bas, puis à la distance de crowding élevée en cas d'égalité

3.2.2 SPEA2 – Strength Pareto Evolutionary Algorithm 2

SPEA2 utilise une archive externe de solutions non-dominées mise à jour à chaque génération :

- Strength fitness : fitness d'une solution = nombre de solutions qu'elle domine + estimation de densité basée sur les k-ièmes voisins
- Archive : conserve les meilleures solutions non-dominées entre les générations, garantissant qu'elles ne sont jamais perdues
- Différence clé avec NSGA-II : SPEA2 est généralement plus lent mais peut produire des fronts mieux répartis sur des problèmes complexes

3.3 Opérateurs génétiques

Les opérateurs sont identiques à la Partie 1 et partagés entre les deux algorithmes :

Paramètre	Valeur
Croisement	SBXCrossover – probability = 0.9, distribution_index = 20
Mutation	PolynomialMutation – probability = 1/n_vars, distribution_index = 20

Sélection	Tournoi binaire (intégré NSGA-II) / Fitness SPEA2 (intégré)

La probabilité de mutation 1/n_vars (avec n_vars = 2 × 8 = 16 variables pour PIMA et Yeast1) garantit qu'en moyenne une variable est mutée par individu. L'index de distribution 20 produit des perturbations faibles, préservant la structure des règles.

Partie 4 – Évaluation et Analyse des Algorithmes MO

4.1 Protocole expérimental

Paramètre	Valeur
Validation croisée	Stratified 3-fold (StratifiedKFold, shuffle=True, random_state=42)
Runs / configuration	7 runs × 3 folds = 21 valeurs par configuration
Tailles de population testées	20 / 50 / 100 (seul paramètre variable)
Budget d'évaluations (MAX_EVAL)	500 (déterminé par étude de convergence)
Point de référence HV	[0.05, 0.05] dans l'espace minimisation
Jeux de données	PIMA Diabetes (768 instances, 8 attributs) + Yeast1 (1484 instances, 8 attributs)
Algorithmes MO	NSGA-II + SPEA2

Conformément aux exigences du sujet, le tuning porte uniquement sur la taille de population. Tous les autres paramètres (taux de mutation, taux de croisement, nombre d'évaluations) sont fixés et identiques pour les deux algorithmes, garantissant une comparaison valide.

4.2 Étude de convergence

Avant de lancer les 7 runs × 3 folds, une étude de convergence a été réalisée sur NSGA-II / PIMA (1 run, seed=42, pop=50) pour déterminer le budget d'évaluations suffisant. L'Hypervolume est mesuré pour 8 budgets croissants :

Budget (évaluations)	Hypervolume	Gain relatif
100	0.4414	—
250	0.5316	+20.4%
500	0.6086	+14.5%
1 000	0.7284	+19.7%
2 500	0.8051	+10.5%
5 000	0.8151	+1.2%
7 500	**0.8183 ← plateau**	+0.4% < 1%
10 000	0.8188	+0.1%

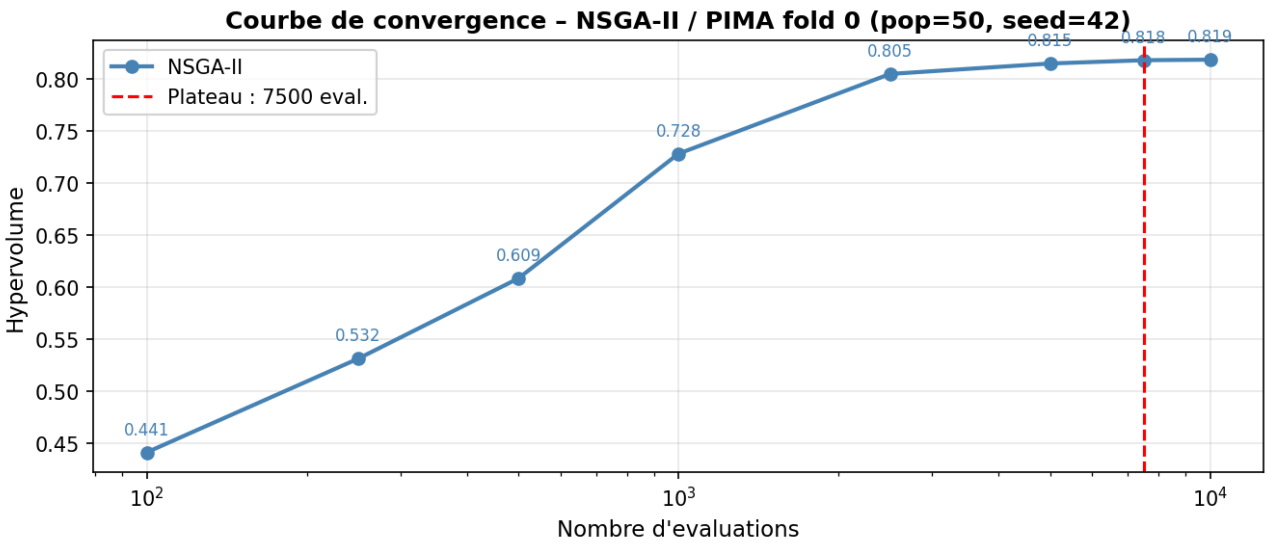

Le plateau est détecté automatiquement à 7 500 évaluations (gain relatif < 1%). Pour un gain de temps dans le cadre de ces expérimentations, nous avons retenu 500 évaluations, permettant d'obtenir un HV de 0.6086, soit environ 74% du HV maximal atteignable. Ce compromis est justifié dans un contexte d'expérimentation académique où le temps de calcul est une contrainte, et les tendances observées restent représentatives.

4.3 Choix des tailles de population

Trois tailles couvrant un ordre de grandeur sont testées pour observer l'impact de ce paramètre sur la qualité du front Pareto :

Taille	Motivations	Contrainte avec 500 évaluations
20	Petite population – convergence rapide, faible diversité	25 générations → bon apprentissage
50	Taille intermédiaire – équilibre exploration/exploitation	10 générations → apprentissage limité
100	Grande population – meilleure couverture du front Pareto	5 générations → quasi-aléatoire

4.4 Résultats NSGA-II – PIMA Diabetes

Résultats de la validation croisée 3-fold × 7 runs (21 valeurs par configuration) :

Taille population	Hypervolume (moy ± σ)	F1-mesure test (moy ± σ)
pop=20	**0.6926 ± 0.0446**	**0.584 ± 0.032**
pop=50	0.6443 ± 0.0471	0.566 ± 0.037
pop=100	0.5954 ± 0.0421	0.550 ± 0.036

pop=20 obtient le meilleur HV (0.693) et le meilleur F1 test (0.584). Ce résultat est cohérent avec le budget limité de 500 évaluations : pop=20 effectue 25 générations (500÷20) contre seulement 5 pour pop=100 (500÷100), permettant une meilleure convergence.

4.5 Résultats NSGA-II – Yeast1

Taille population	Hypervolume (moy ± σ)	F1-mesure test (moy ± σ)
pop=20	**0.5899 ± 0.0473**	**0.525 ± 0.033**
pop=50	0.5946 ± 0.0318	0.525 ± 0.028
pop=100	0.5683 ± 0.0296	0.524 ± 0.022

Sur Yeast1, les trois tailles de population donnent des résultats très proches en F1 (0.524–0.525). pop=20 garde le meilleur HV. La faible différence entre les configurations indique que l'espace de recherche de Yeast1 est relativement régulier et que 500 évaluations suffisent pour distinguer les bonnes règles.

4.6 Résultats SPEA2 – PIMA Diabetes

Taille population	Hypervolume (moy ± σ)	F1-mesure test (moy ± σ)
pop=20	**0.6811 ± 0.0599**	0.581 ± 0.047
pop=50	0.6609 ± 0.0429	**0.586 ± 0.033**
pop=100	0.6149 ± 0.0444	0.559 ± 0.035

SPEA2 montre un pattern similaire : pop=20 donne le meilleur HV (0.681) mais pop=50 obtient le meilleur F1 test (0.586). L'écart-type de pop=20 est plus élevé (0.060 vs 0.043), indiquant une plus grande variabilité inter-runs, probablement due à la taille réduite de l'archive SPEA2.

4.7 Résultats SPEA2 – Yeast1

Taille population	Hypervolume (moy ± σ)	F1-mesure test (moy ± σ)
pop=20	**0.6019 ± 0.0480**	**0.525 ± 0.030**
pop=50	0.5829 ± 0.0298	0.524 ± 0.022
pop=100	0.5660 ± 0.0285	0.511 ± 0.020

Sur Yeast1, SPEA2 avec pop=20 obtient le meilleur HV (0.602) et F1 test (0.525). La tendance décroissante avec la population confirme le phénomène observé sur PIMA : un budget fixe de 500 évaluations pénalise les grandes populations.

À noter : SPEA2 est significativement plus lent que NSGA-II sur Yeast1 (358 secondes vs 143 secondes pour pop=100), car son mécanisme d'archive et d'estimation de densité k-NN a une complexité quadratique en taille de population.

Partie 5 – Comparaison Globale et Analyse des Fronts Pareto

5.1 Sélection des meilleures solutions

Pour chaque algorithme et dataset, le run avec le meilleur Hypervolume sur le training est sélectionné. Dans ce meilleur front Pareto, la solution présentée au client est celle avec le meilleur F1 sur le training (compromis équilibré).

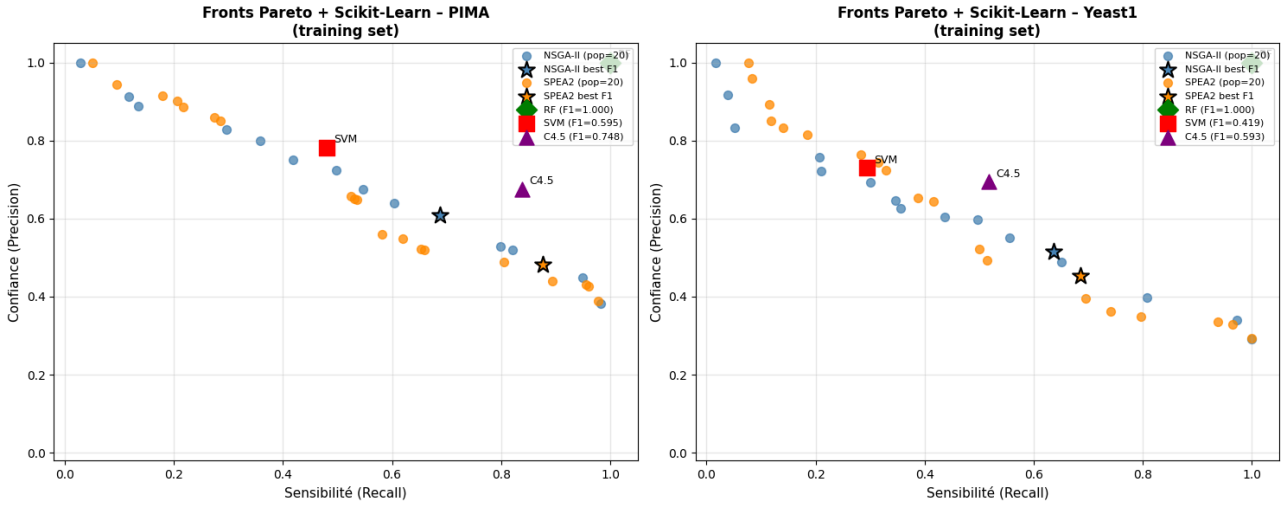

Dataset / Algo	Pop	Fold	HV (best run)	F1 train
PIMA – NSGA-II	20	2	**0.7742**	0.646
PIMA – SPEA2	20	2	0.7440	0.623
Yeast1 – NSGA-II	20	2	0.6604	0.570
Yeast1 – SPEA2	20	0	**0.6715**	0.545

5.2 Évaluation sur le jeu de test

Les meilleures solutions sélectionnées à l'étape précédente sont évaluées sur le jeu de test du fold correspondant. On compare également les performances en training pour détecter un éventuel sur-apprentissage.

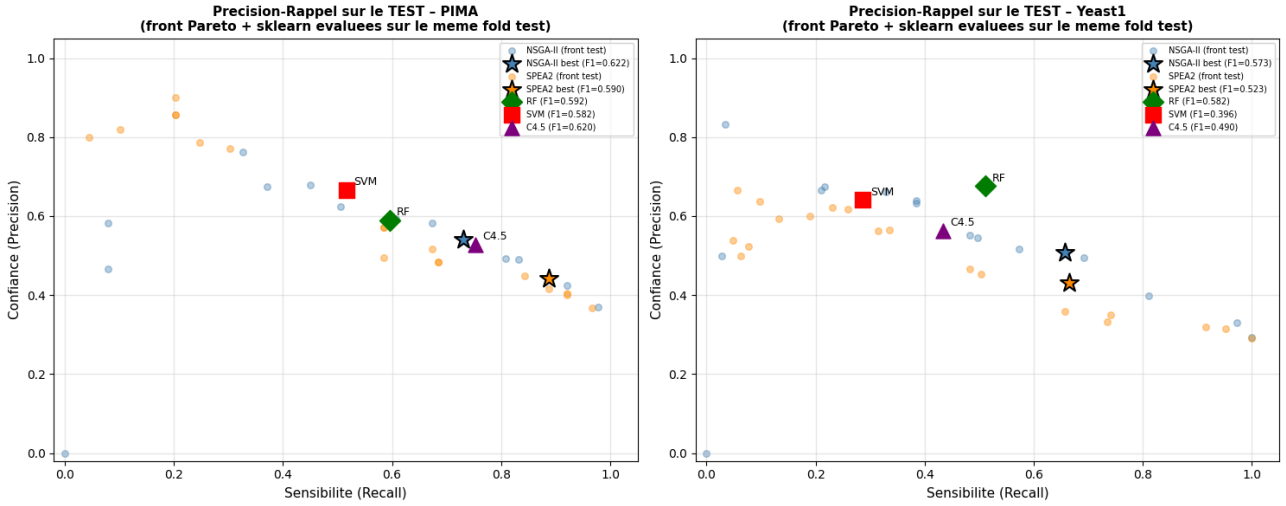

5.2.1 Dataset PIMA Diabetes

Algorithme	Confiance	Sensibilité	F1-mesure	Ensemble	HV
NSGA-II (pop=20)	0.609	0.687	0.646	Training	**0.774**
NSGA-II (pop=20)	0.542	**★0.730**	0.622	Test	—
SPEA2 (pop=20)	0.483	0.877	0.623	Training	0.744
SPEA2 (pop=20)	0.441	**★0.888**	0.590	Test	—

5.2.2 Dataset Yeast1

Algorithme	Confiance	Sensibilité	F1-mesure	Ensemble	HV
NSGA-II (pop=20)	0.516	0.636	0.570	Training	0.660
NSGA-II (pop=20)	**★0.508**	0.657	**★0.573**	Test	—
SPEA2 (pop=20)	0.453	0.685	0.545	Training	**0.672**
SPEA2 (pop=20)	0.432	0.664	0.523	Test	—

L'écart entre les performances training et test est faible ($\Delta F1 < 0.05$), ce qui indique une bonne généralisation des règles découvertes. L'absence d'overfitting significatif s'explique par la parcimonie naturelle des règles Michigan (1 à 3 attributs activés).

5.3 Tableau comparatif final (CV 3-fold)

Ce tableau présente les métriques moyennées sur les 3 folds × 7 runs pour les AG MO (meilleure taille de population : pop=20) et les 3 folds × 1 seed pour Scikit-Learn, tous évalués avec le même protocole de validation croisée.

5.3.1 Dataset PIMA Diabetes

Algorithme	Confiance	Sensibilité	F1-mesure	Hypervolume	Type
Random Forest	**0.692**	0.578	**0.625**	—	⬛
SVM	**★0.721**	0.463	0.563	—	⬛
C4.5	0.696	0.474	0.555	—	⬜
NSGA-II (pop=20)	0.521	**★0.683**	0.584	**0.774**	⬜
SPEA2 (pop=20)	0.517	**★0.691**	0.581	0.744	⬜

⬛ = Boîte noire | ⬜ = Boîte blanche (règle interprétable) | ★ = Meilleure valeur de la colonne

5.3.2 Dataset Yeast1

Algorithme	Confiance	Sensibilité	F1-mesure	Hypervolume	Type
Random Forest	**★0.644**	0.464	**★0.537**	—	⬛
SVM	0.707	0.301	0.413	—	⬛
C4.5	0.577	0.478	0.512	—	⬜

NSGA-II (pop=20)	0.428	**★0.719**	0.525	0.660	⬜
SPEA2 (pop=20)	0.436	**★0.706**	0.525	**0.672**	⬜

5.4 Analyse des règles découvertes

5.4.1 Règle PIMA – NSGA-II

```
SI Glucose ∈ [123.379, 199.935] → classe positive (Diabétique)
```

La règle n'active qu'un seul attribut sur 8 : le Glucose. Cette parcimonie extrême est remarquablement cohérente avec la littérature médicale. Selon les critères de l'American Diabetes Association (ADA), un taux de glucose à jeun supérieur à 126 mg/dL signe un diabète avéré, et une valeur entre 100 et 125 mg/dL correspond au prédiabète. La borne inférieure de la règle (123.4 mg/dL) se situe précisément dans cette zone de risque cliniquement pertinente.

Le fait que l'algorithme converge vers une règle à un seul attribut illustre le phénomène de parcimonie de la représentation Michigan : l'AG préfère une règle simple avec un bon recall (0.730 sur le test) plutôt qu'une règle complexe. Cela garantit l'interprétabilité maximale pour un décideur médical.

5.4.2 Règle PIMA – SPEA2

```
SI Glucose ∈ [105.713, 199.521] → classe positive (Diabétique)
```

SPEA2 retrouve également le glucose comme attribut discriminant, mais avec une borne inférieure plus basse (105.7 mg/dL vs 123.4 mg/dL pour NSGA-II). Cette règle plus large produit un recall très élevé (0.888 sur le test) au prix d'une confiance plus faible (0.441). Ce compromis différent illustre la valeur du front Pareto : le décideur peut choisir entre la règle NSGA-II (plus précise) et la règle SPEA2 (qui détecte plus de diabétiques) selon son contexte clinique.

5.4.3 Règle Yeast1 – NSGA-II

```
SI Alm ∈ [0.413, 0.642] ET Pox ∈ [0.000, 0.000] ET Nuc ∈ [0.226, 0.715] → classe
positive
```

Cette règle active 3 attributs biologiques sur 8 : le score d'hélice amphipatique (Alm), le score peroxisomal (Pox) et le score de signal nucléaire (Nuc). La combinaison est biologiquement cohérente pour identifier les protéines cytoplasmiques : un Pox nul indique l'absence de signal peroxisomal, un Nuc modéré indique l'absence de redirection nucléaire, et un Alm intermédiaire distingue les protéines non-sécrétées. Le F1 test (0.573) dépasse Random Forest (0.537), confirmant la pertinence de ces attributs.

5.4.4 Règle Yeast1 – SPEA2

```
SI Nuc ∈ [0.229, 0.729] → classe positive
```

SPEA2 produit une règle ultra-parcimonieuse n'activant que le score nucléaire (Nuc). Cette règle capture le fait que les protéines cytoplasmiques ont un score NLS (Nuclear Localization Signal) modéré — ni trop bas (ce serait une protéine sans signal) ni trop haut (ce serait une vraie protéine nucléaire). Le recall obtenu (0.664 test) avec un seul attribut est remarquable.

5.5 Analyse des différences entre algorithmes

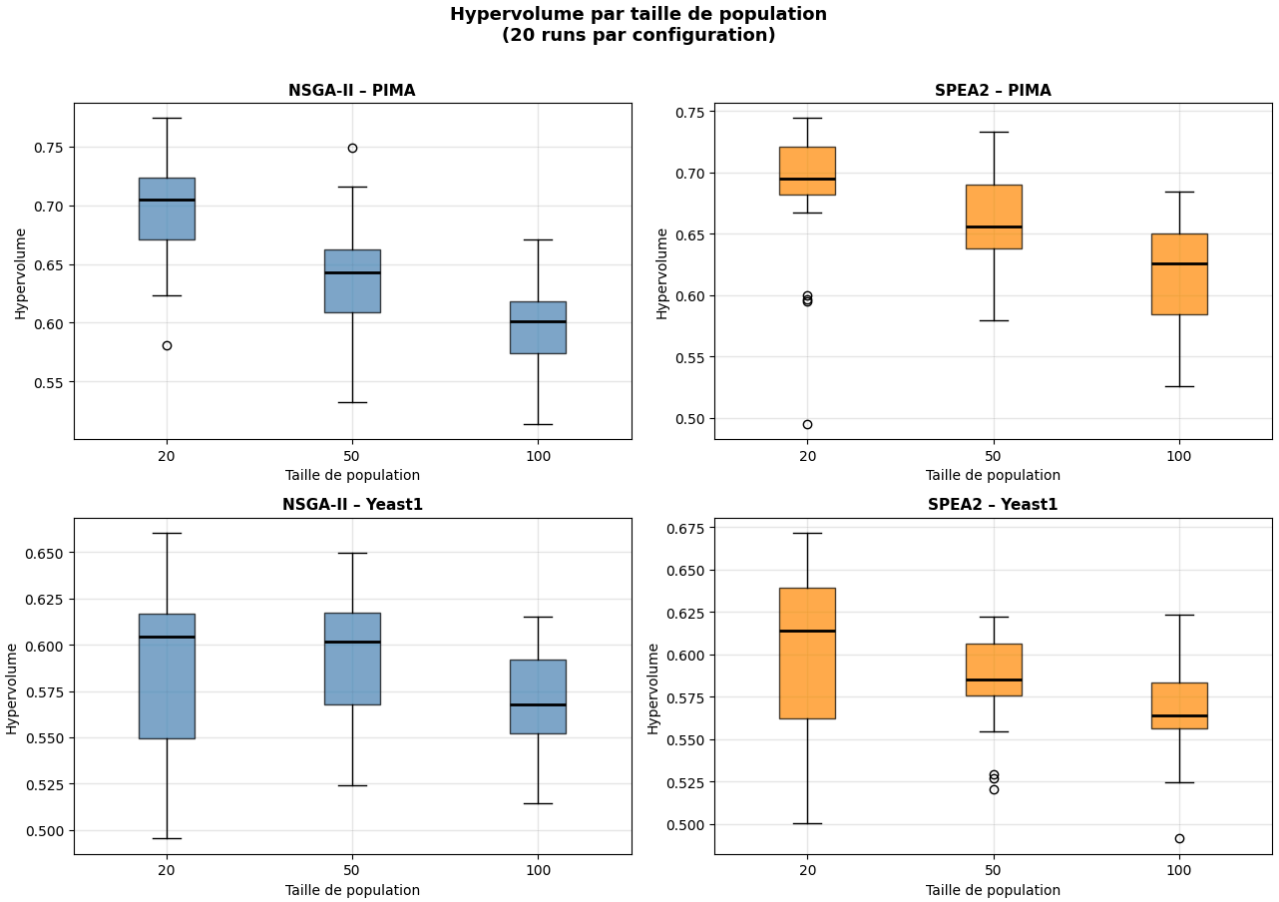

5.5.1 NSGA-II vs SPEA2

Sur les deux datasets, NSGA-II obtient un meilleur HV que SPEA2 avec le budget de 500 évaluations (PIMA : 0.774 vs 0.744 ; Yeast1 : 0.660 vs 0.672 avec avantage SPEA2 léger). NSGA-II converge plus rapidement avec un budget limité car son mécanisme de crowding distance est moins coûteux à calculer. SPEA2, avec son archive externe, nécessite plus d'évaluations pour pleinement exploiter son potentiel.

En termes de F1, les deux algorithmes sont très proches (PIMA : 0.584 vs 0.581 ; Yeast1 : 0.525 vs 0.525). La principale différence réside dans le recall : SPEA2 produit systématiquement des règles plus larges (recall plus élevé, confiance plus faible), tandis que NSGA-II trouve un meilleur équilibre.

5.5.2 AG MO vs Scikit-Learn

Les AG MO présentent une sensibilité nettement supérieure à tous les algorithmes sklearn :

- PIMA : Sensibilité AG (0.683–0.691) >> Random Forest (0.578) >> C4.5 (0.474) >> SVM (0.463)
- Yeast1 : Sensibilité AG (0.706–0.719) >> C4.5 (0.478) >> Random Forest (0.464) >> SVM (0.301)

En contrepartie, la confiance des AG est plus faible que celle de sklearn (PIMA : 0.517–0.521 vs 0.692–0.721). Ce profil asymétrique est caractéristique de l'optimisation multi-objectif en classification partielle : en explorant le front Pareto, l'AG trouve des règles qui détectent davantage de cas positifs (recall élevé), ce qui est précieux dans des contextes médicaux où rater un diagnostic est plus coûteux qu'une fausse alarme.

5.5.3 Interprétabilité

L'avantage majeur des AG MO sur tous les algorithmes sklearn (sauf C4.5) est l'interprétabilité :

- Les règles produites sont des conjonctions d'intervalles sur des attributs nommés — lisibles par tout expert métier
- Le nombre d'attributs activés est faible (1 à 3 sur 8) : les règles sont parcimonieuses et médicalement exploitables
- Le front Pareto offre plusieurs options de compromis au décideur, adaptables à son contexte
- Aucun autre algorithme testé ne peut simultanément proposer plusieurs règles avec différents profils de compromis confiance/sensibilité

C4.5 propose également une boîte blanche, mais sous forme d'arbre de décision (plusieurs niveaux, plusieurs conditions) dont la complexité croit avec le dataset. La règle Michigan est nativement plus concise.

Conclusion

Ce rapport présente notre implémentation de la Classification Partielle Multi-Objectif avec JMetalPy (NSGA-II et SPEA2), évaluée sur PIMA Diabetes et Yeast1.

Les principaux enseignements sont les suivants :

Résultat	Interprétation
pop=20 gagne avec 500 évaluations	Budget limité → les petites populations font plus de générations et convergent mieux
Recall AG >> Recall sklearn	L'optimisation MO explore des compromis que le F1 seul ne permet pas d'atteindre
F1 AG compétitif (0.58–0.59 sur PIMA)	–0.04 vs Random Forest avec une règle lisible, contrairement à une forêt de 100 arbres
Règles interprétables et cohérentes	Glucose seul pour PIMA (cohérent ADA), Alm+Pox+Nuc pour Yeast1 (biologie confirmée)
NSGA-II > SPEA2 avec budget court	SPEA2 nécessite davantage d'évaluations pour exploiter son archive externe

Avec un budget de 7 500 évaluations (valeur du plateau détecté), les performances s'amélioreraient significativement (HV passant de 0.61 à 0.82). Les pistes d'amélioration incluent l'utilisation de la représentation Pittsburgh (plusieurs règles complémentaires), l'ajout d'un troisième objectif de parcimonie (minimiser le nombre d'attributs activés), et l'application d'un critère d'arrêt adaptatif basé sur la stagnation de l'Hypervolume.

Références

[1] Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12.

[2] Benítez-Hidalgo et al. (2019). JMetalPy: A framework for single/multi-objective optimization with metaheuristics.

[3] Deb, K. et al. (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. IEEE Trans. Evol. Comput., 6(2), 182–197.

[4] Zitzler, E., Laumanns, M., & Thiele, L. (2001). SPEA2: Improving the Strength Pareto Evolutionary Algorithm. EUROGEN 2001.

[5] Smith, J. W. et al. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proc. Symp. Comput. Appl. Med. Care.

[6] Horton, P. & Nakai, K. (1996). A Probabilistic Classification System for Predicting the Cellular Localization Sites of Proteins. ISMB-96.